

Classificação de Engajamento em EaD com Visão Computacional

Priscila Henrique Medeiro dos Santos (priscilahms@yahoo.com.br)
Santo André, agosto de 2026

1. Resumo

O acompanhamento do engajamento discente em aulas síncronas de Educação a Distância (EaD) esbarra nos limites da percepção humana: o docente não observa simultaneamente dezenas de participantes, o que retarda a detecção de desengajamento e alimenta a evasão [2][3][4]. No dataset de referência da área, o DAiSEE [1], a literatura reporta majoritariamente acurácia como métrica única, subtratando um desbalanceamento extremo (as duas classes de baixo engajamento somam menos de 6% dos cliques) e a natureza ordinal do rótulo. Este trabalho entrega uma Prova de Conceito leve e preservadora de privacidade: marcos faciais, íris/gaze e pose da cabeça extraídos com MediaPipe FaceMesh [17], agregados por clipe e classificados por modelos clássicos (Trilha A) e por uma rede temporal rasa BiLSTM (Trilha B), com comparação explícita de estratégias de balanceamento e da formulação ordinal CORAL [16]. A avaliação usa os splits oficiais disjuntos por sujeito e um protocolo multimétrica (acurácia, macro-F1, kappa de Cohen, revocação por classe) com intervalos de confiança por bootstrap, confrontando o modelo com o baseline trivial de classe majoritária. O melhor modelo atingiu macro-F1 de 0,382 e kappa de 0,111 contra 0,171 e 0,000 do baseline, levando a hipótese a ser considerada parcialmente corroborada.

2. Introdução e Motivação

Em ambientes virtuais de aprendizagem, o professor perde os sinais não verbais que, na sala presencial, sinalizam tédio, confusão ou dispersão. A literatura associa essa cegueira situacional à queda de motivação e a elevadas taxas de evasão [3][4]. Automatizar a leitura desses sinais a partir do vídeo já capturado pelas webcams é, portanto, uma intervenção de baixo custo marginal com potencial pedagógico direto. O desafio é que engajamento não é uma emoção básica: é um estado acadêmico difuso, anotado de forma ordinal e altamente desbalanceada, e observado “in the wild”, com iluminação, enquadramento e qualidade heterogêneos.

Questões de pesquisa. (QP1) Quais indicadores visuais extraíveis em tempo real – abertura ocular, direção do olhar, pose da cabeça, movimentação da boca – estão mais associados aos níveis de engajamento? (QP2) Modelos treinados apenas sobre marcos faciais, sem transmitir ou armazenar a imagem do rosto, conseguem separar estudantes engajados de desengajados em vídeo real com desempenho superior a um classificador trivial?

Hipótese. Modelos de visão computacional que analisam continuamente indicadores comportamentais (expressões faciais, orientação da cabeça, comportamentos de distração) permitem identificar níveis de engajamento com maior objetividade do que o acompanhamento humano não instrumentado. No recorte desta PoC, a hipótese é

operacionalizada de forma falseável: o modelo deve superar o baseline de classe majoritária em macro-F1 e kappa com intervalos de confiança de 95% não sobrepostos.

Contribuições esperadas. (i) um protocolo de avaliação mais rigoroso que o predominante na literatura do DAiSEE, reportando macro-F1, kappa, revocação por classe e intervalos de confiança, e não apenas acurácia; (ii) evidência empírica sobre quanto do sinal de engajamento é recuperável a partir de marcos faciais leves, executáveis em hardware comum e com preservação de privacidade; (iii) uma ablação explícita de estratégias de balanceamento e de formulação ordinal, dimensionando o quanto o desbalanceamento – e não a arquitetura – limita o desempenho nesta tarefa.

3. Estado da Arte e Trabalhos Relacionados

O benchmark original do DAiSEE [1] estabeleceu 57,9% de acurácia com uma rede LRCN. A evolução seguinte combinou extratores espaciais profundos com modelagem temporal: o DFSTN [7] alcançou 58,8% com SE-ResNet-50 e LSTM com atenção, e o 3D DenseAttNet [8] chegou a 63,6% com autoatenção sobre cubos espaço-temporais. Duas linhas se mostraram mais produtivas que o simples aumento de capacidade. A primeira trata o rótulo como ordinal: Abedi e Khan [5] obtiveram 67,4% modelando engajamento como variável ordenada, e o trabalho contrastivo ordinal de Safa et al. [14] ataca diretamente a combinação de ordinalidade com classes raras. A segunda questiona a necessidade de modelar a ordem temporal: o Bag of States [9] atingiu 66,6% tratando o clipe como conjunto não ordenado de estados, resultado que enfraquece a premissa de que arquiteturas sequenciais pesadas sejam indispensáveis.

Para o recorte desta PoC, a evidência mais relevante é a de que representações compactas bastam. Abedi e Khan [6] usaram exclusivamente marcos do MediaPipe FaceMesh alimentando uma ST-GCN, obtendo desempenho de ponta em bases correlatas com custo baixo e sem trafegar imagens de rosto – propriedade de privacidade relevante em contexto educacional. Sugihdharma e Bachtar [10] reportaram a maior acurácia revisada usando apenas marcos oculares e gaze, embora o valor (95,8%) destoe tanto da faixa dos demais trabalhos (58% a 73%) que seu protocolo precisa ser verificado antes de servir como cota superior. Em contrapartida, a fusão multimodal tem custo-benefício desfavorável: o VisioPhysioENet [11] adiciona sinais fisiológicos rPPG e fica em 63,1%. O estado da arte reportado é o ViBED-Net [13], com 73,4%, e o EngageFormer [12] atinge 63,9% – ambos com custo de treino muito acima do orçamento desta PoC. Por fim, um benchmark zero-shot de modelos de fundação [15] obteve kappa inferior a 0,10 no DAiSEE, com colapso das predições em uma única classe, o que justifica investir em treino supervisionado em vez de prompting.

Diferenciação. Quase todos os trabalhos acima reportam acurácia como métrica central, o que é enganoso quando duas classes concentram mais de 94% dos exemplos: responder sempre “engajado” já rende cerca de 49% de acurácia. Poucos relatam kappa, macro-F1 ou revocação das classes raras, e menos ainda reportam intervalos de confiança. Este projeto não busca superar o número absoluto do ViBED-Net, e sim medir honestamente o que atributos faciais leves entregam sob um protocolo que torne visível o efeito do desbalanceamento – a lacuna metodológica que a área vem carregando.

4. Objetivos

Objetivo geral. Avaliar se indicadores visuais permitem identificar diferentes níveis de engajamento de estudantes em aulas síncronas de EaD. **Critério de verificação:** o melhor modelo deve superar o baseline de classe majoritária em macro-F1 e kappa, com intervalos de confiança de 95% (bootstrap, 1.000 reamostragens) não sobrepostos.

Objetivo específico 1. Identificar os indicadores visuais mais relacionados ao engajamento, ao desengajamento e à distração. **Critério:** produzir um ranking de importância de atributos com estabilidade do top-5 em pelo menos 4 de 5 folds de validação cruzada estratificada.

Objetivo específico 2. Avaliar a capacidade de modelos baseados em marcos faciais de diferenciar estudantes engajados de desengajados em vídeos reais. **Critério:** na formulação binária (Desengajado = níveis 0 e 1; Engajado = níveis 2 e 3), atingir revocação da classe minoritária maior ou igual a 60% e AUC-ROC maior ou igual a 0,70, contra revocação próxima de zero do baseline trivial.

Os três critérios são definidos a priori e são falseáveis: qualquer um dos desfechos – hipótese corroborada, parcialmente corroborada ou não corroborada – constitui resultado reportável, e a delimitação a uma PoC sobre dataset público mantém os objetivos alcançáveis no prazo do mestrado.

5. Metodologia, Plano de Trabalho e Cronograma

Dados e pré-processamento. Utilizou-se o DAiSEE [1], com clipes de 10 s a 30 fps e resolução 640×480, rotulados de 0 a 3 em Engajamento, Tédio, Confusão e Frustração. Foram respeitados os splits oficiais, disjuntos por sujeito (69, 19 e 21 sujeitos em treino, validação e teste), condição necessária para comparabilidade com a literatura. Dos 8.571 clipes rotulados nos três splits, 7.918 foram localizados em disco e processados. De cada clipe amostraram-se 20 quadros uniformemente espaçados – e não todos os quadros – e de cada quadro extraíram-se, via MediaPipe FaceMesh com refinamento de íris [17]: EAR (abertura ocular), MAR (abertura bucal), pose da cabeça (yaw, pitch e roll por solvePnP) e posição normalizada da íris (gaze horizontal, vertical e desvio em relação ao centro). Quadros sem rosto detectado recebem marcação explícita, e a taxa de detecção entra como atributo; a detecção facial média foi de 99,99%. Os atributos por quadro são agregados por clipe (média, desvio, mínimo e máximo), gerando 33 atributos tabulares. O ângulo de roll exigiu correção de descontinuidade circular: por concentrar-se junto de $\pm 180^\circ$, seu desvio-padrão vinha inflado em 25,4% dos clipes.

Modelagem. A Trilha A treina Random Forest, XGBoost e SVM sobre os atributos agregados, com GridSearchCV e validação cruzada estratificada dentro do treino, comparando quatro tratamentos de desbalanceamento: nenhum, class_weight balanceado, SMOTE e ponderação por inverso de frequência. A Trilha B treina uma BiLSTM rasa sobre a sequência de 20 passos por clipe, com perda focal ponderada por classe e parada antecipada monitorando macro-F1 de validação, além de uma variante ordinal CORAL [16] que substitui a saída softmax por limiares cumulativos. A extração de marcos é feita em CPU (a inferência do MediaPipe não usa GPU nesta configuração) e a Trilha B é treinada em GPU NVIDIA RTX 4060; ambos os modelos são suficientemente leves para execução em hardware de uso pessoal. A semente aleatória é fixada em 42 e as versões das bibliotecas são congeladas para garantir reprodutibilidade.

Resultados. A tabela abaixo consolida o desempenho no conjunto de teste (1.638 cliques).

Modelo	Acurácia	Macro-F1	Kappa
Random Forest (class_weight=balanced)	0,527	0,382	0,111
XGBoost (ponderação por classe)	0,483	0,346	0,052
Random Forest + SMOTE	0,491	0,282	0,079
BiLSTM ordinal (CORAL)	0,524	0,266	0,061
Random Forest (sem balanceamento)	0,515	0,247	0,041
SVM (class_weight=balanced)	0,362	0,208	0,034
Baseline trivial (classe majoritária)	0,518	0,171	0,000
BiLSTM + perda focal (ponderada)	0,157	0,121	0,033

O bootstrap com 1.000 reamostragens sobre o teste situa o melhor modelo em macro-F1 0,378 (IC95% [0,307; 0,481]) e kappa 0,110 (IC95% [0,068; 0,152]), contra macro-F1 0,172 (IC95% [0,166; 0,177]) e kappa 0,000 do baseline trivial. Os intervalos não se sobrepõem, caracterizando ganho estatisticamente significativo sobre o baseline. No Objetivo 2, a formulação binária alcançou revocação de 25,9% para a classe Desengajado e AUC-ROC de 0,731. Quanto ao Objetivo 1, o top-5 de atributos foi ear_mean, ear_min, gaze_v_std, ear_std, gaze_h_std, dos quais 4 permaneceram no top-5 em pelo menos 4 dos 5 folds. Vale registrar que a formulação ordinal CORAL superou a variante nominal com perda focal na Trilha B (macro-F1 de 0,266 contra 0,121), indicando que preservar a ordem dos níveis ajuda mais que reponderar classes de forma agressiva.

O desfecho é de corroboração parcial: há ganho estatisticamente significativo sobre o baseline em macro-F1 e kappa, confirmando que os marcos faciais carregam sinal real de engajamento, mas a revocação da classe Desengajado ficou muito abaixo da meta de 60%. O fator limitante, portanto, não é a ausência de sinal, e sim o desbalanceamento extremo: mesmo com ponderação de classes, SMOTE e perda focal, as classes raras permanecem sub-representadas a ponto de nenhuma das mitigações testadas as recuperar plenamente. Um kappa de 0,11 indica concordância apenas ligeiramente superior ao acaso, insuficiente para uso pedagógico direto, ainda que suficiente para demonstrar que o sinal existe. Esse é precisamente o diagnóstico que a acurácia, métrica dominante na literatura, tornaria invisível: o baseline trivial atinge 51,8% de acurácia, valor que isolado pareceria competitivo.

Limitações. (i) a amostragem de 20 quadros por clipe descarta microdinâmicas rápidas; (ii) o conjunto de teste contém apenas 4 cliques da classe 0, o que torna o macro-F1 sensível a poucos acertos e amplia os intervalos de confiança; (iii) marcos faciais descartam contexto de cena e postura corporal, usados pelos modelos de ponta [13]; (iv) a PoC restringiu-se deliberadamente a atributos geométricos leves, de modo que backbones visuais pré-treinados – viáveis no hardware disponível – ainda não foram explorados; (v) há indícios de ruído de rótulo por sujeito, já documentados na literatura.

Plano de trabalho e cronograma. A PoC foi organizada em seis etapas reprodutíveis, já executadas: (1) preparação de ambiente e validação do dataset; (2) análise exploratória; (3) extração de marcos faciais; (4) linha de base clássica e ranking de atributos; (5) modelo temporal e variante ordinal; (6) avaliação comparativa e bootstrap.

No horizonte do mestrado, seguem-se: meses 1 a 3, validação cruzada em bases adicionais (EngageNet, Student Engagement Dataset) para medir generalização entre domínios; meses 4 a 7, contexto de cena via backbone pré-treinado e aprendizado contrastivo ordinal [14], já viáveis na GPU local; meses 8 a 10, ruído de rótulo por sujeito e calibração de incerteza; meses 11 a 14, protótipo de painel de feedback ao docente e avaliação com professores; meses 15 a 18, redação e defesa.

6. Referências

- [1] GUPTA, A. et al. DAiSEE: Towards User Engagement Recognition in the Wild. arXiv:1609.01885, 2016.
- [2] LEE, H. et al. Investigating the Effects of a Real-time Student Monitoring Interface on Instructors' Monitoring Practices in Online Teaching. 2024.
- [3] NASCIMENTO, M. D. et al. Computational Vision for Analyzing Student Emotions in E-learning: a Preliminary Study. 2023.
- [4] MRAYHI, S. et al. Enhancing MOOCs through Real-time Learner Engagement and Emotion Detection Using Computer Vision and Machine Learning. 2024.
- [5] ABEDI, A.; KHAN, S. S. Affect-driven Ordinal Engagement Measurement from Video. arXiv:2106.10882, 2021.
- [6] ABEDI, A.; KHAN, S. S. Engagement Measurement Based on Facial Landmarks and Spatial-Temporal Graph Convolutional Networks. arXiv:2403.17175, 2024.
- [7] LIAO, J.; LIANG, Y.; PAN, J. Deep Facial Spatiotemporal Network for Engagement Prediction in Online Learning. Applied Intelligence, 2021. DOI:10.1007/s10489-020-02139-8.
- [8] MEHTA, N. K. et al. Three-dimensional DenseNet Self-attention Neural Network for Automatic Detection of Student's Engagement. Applied Intelligence, 2022. DOI:10.1007/s10489-022-03200-4.
- [9] ABEDI, A. et al. Bag of States: A Non-sequential Approach to Video-based Engagement Measurement. arXiv:2301.06730, 2023.
- [10] SUGIHDHARMA, M. R.; BACHTIAR, F. A. Engagement and Affective State Detection Using Scaled Dot-Product Attention CNN on Eye Landmarks and Gaze. 2023. DOI:10.1145/3626641.3626938.
- [11] SINGH, A. et al. VisioPhysioENet: Multimodal Engagement Detection Using Visual and Physiological Signals. arXiv:2409.16126, 2024.
- [12] MANDIA, S. et al. EngageFormer: Multi-view Transformer for Student Engagement Recognition. arXiv:2502.10813, 2025.
- [13] GOTHWAL, A. et al. ViBED-Net: Video-Based Engagement Detection Network. arXiv:2510.18016, 2025.
- [14] SAFA, M.; ABEDI, A.; KHAN, S. S. Supervised Contrastive Ordinal Learning for Engagement Measurement. arXiv:2505.20676, 2025.
- [15] GOYAL, N. et al. Zero-Shot Vision-Language Models for Student Engagement Recognition: A Benchmark. arXiv:2606.21861, 2026.
- [16] CAO, W.; MIRJALILI, V.; RASCHKA, S. Rank Consistent Ordinal Regression for Neural Networks (CORAL). Pattern Recognition Letters, v. 140, p. 325-331, 2020.
- [17] LUGARESI, C. et al. MediaPipe: A Framework for Building Perception Pipelines. arXiv:1906.08172, 2019.