

Classificação de Engajamento em EaD com Visão Computacional

Priscila Henrique Medeiro dos Santos (priscilahms@yahoo.com.br)
Santo André, 11 de julho de 2026

1. Objetivos

- **Geral:** Avaliar se indicadores visuais permitem identificar diferentes níveis de engajamento de estudantes em aulas síncronas de Educação a Distância (EaD).
- **Específicos:** - Identificar os indicadores visuais mais relacionados ao engajamento, desengajamento e distração no aprendizado online.
- Avaliar a capacidade de modelos baseados em marcos faciais para diferenciar estudantes engajados e desengajados em vídeos reais..

Embora a avaliação ou até o desenvolvimento de soluções mais abrangentes constituam o objetivo da dissertação de mestrado, este trabalho de miniquificação delimita-se ao desenvolvimento de uma Prova de Conceito (Proof of Concept – PoC), fundamentada em datasets públicos e modelos pré-treinados, representando a etapa inicial do percurso de pesquisa proposto.

2. Problema de Pesquisa e Hipótese

- **Problema:** Professores de EaD enfrentam limitações inerentes à percepção humana que impedem o acompanhamento simultâneo e objetivo de múltiplos estudantes (LEE et al., 2024). Essa lacuna dificulta a detecção de sinais sutis de desengajamento, tédio e frustração, que, se não identificados em tempo hábil, comprometem a motivação e a persistência do aluno (NASCIMENTO et al., 2023). Como consequência, a incapacidade de supervisão contínua em tempo real torna-se um dos principais fatores para as elevadas taxas de evasão e a baixa retenção características dos ambientes virtuais de aprendizagem (NASCIMENTO et al., 2023; MRAYHI et al., 2024).

- **Hipótese:** A utilização de modelos de Inteligência Artificial baseados em visão computacional para analisar indicadores comportamentais de estudantes, como expressões faciais, orientação da cabeça e comportamentos de distração, em aulas síncronas de Educação a Distância (EaD), permite identificar níveis de engajamento com maior precisão e objetividade do que os métodos tradicionais de acompanhamento, devido à capacidade desses algoritmos de processar continuamente tais indicadores e fornecer aos docentes informações de forma mais ágil e precisa.

3. Estado da Arte

A fronteira do conhecimento nessa área concentra-se na superação de desafios relacionados ao processamento computacional para mitigar as limitações da percepção humana no monitoramento docente simultâneo de múltiplos estudantes (LEE et al., 2024). Observa-se a evolução da análise de emoções básicas para a identificação de emoções acadêmicas complexas (como tédio, confusão e frustração), que são mais representativas do engajamento e do esforço cognitivo no processo de aprendizagem (XU et al., 2024; KE et al., 2025; LIU e WANG, 2025). Paralelamente, a pesquisa foca no desenvolvimento de modelos leves e eficientes, baseados em arquiteturas de baixo parâmetro, capazes de operar em tempo real em dispositivos com recursos computacionais limitados e hardware padrão de estudantes (SAVCHENKO et al., 2022; RAHMAN et al., 2025; DUDHMAL et al., 2025).

Assim, o avanço da pesquisa deixa de se restringir à detecção de faces e passa a focar na quantificação do engajamento por meio da fusão, em tempo real, de múltiplos indicadores visuais, como direção do olhar (gaze), orientação da cabeça (head pose) e microexpressões faciais (BABAEI et al., 2020; SUGIHDHARMA e BACHTIAR, 2023; WANG et al., 2025). Utilizando tecnologias para fornecimento de feedback imediato aos docentes, subsidiando a tomada de decisões pedagógicas e intervenções dinâmicas (GOH et al., 2025; KE et al., 2025). Para garantir a objetividade e a precisão dessa monitoria, a validação técnica desses sistemas podem ocorrer através de datasets públicos.

4. Referências

- a. **DELGADO, K. et al. Student Engagement Dataset. 2021.** (Trabalho fundamental sobre o uso de datasets para detecção de engajamento e distração).
- b. **GOH, M. L. I. et al. Classroom Engagement through Real-time Student Attention Analysis using YOLO V8. 2025.** (Justifica o uso de arquiteturas YOLO para análise em tempo real).
- c. **GUPTA, A. et al. DAiSEE: Towards user engagement recognition in the wild. 2016.** (Referência padrão para o dataset utilizado na validação de engajamento em EaD).
- d. **KE, L.-Y. et al. A Visual Mamba-based Architecture for Student Engagement Recognition in Distance Learning Environments. 2025.** (Apresenta a fronteira tecnológica e o foco em emoções acadêmicas).
- e. **LEE, H. et al. Investigating the Effects of a Real-time Student Monitoring Interface on Instructors' Monitoring Practices in Online Teaching. 2024.** (Base para o problema da fadiga docente e eficácia do monitoramento).
- f. **MRAYHI, S. et al. Enhancing MOOCs through Real-time Learner Engagement and Emotion Detection Using Computer Vision and Machine Learning. 2024.** (Conecta o monitoramento de engajamento com a redução de taxas de evasão).
- g. **NASCIMENTO, M. D. et al. Computational vision for analyzing student emotions in e-learning: a preliminary study. 2023.** (Justifica o uso da IA para prever riscos de evasão e desengajamento).
- h. **RAHMAN, M. et al. A Lightweight CNN Architecture for Precise Analysis of Student Concentration and Distraction in Online Learning. 2025.** (Fundamenta o uso de modelos leves e eficientes para dispositivos comuns).
- i. **SAVCHENKO, A. V. et al. Classifying Emotions and Engagement in Online Learning Based on a Single Facial Expression Recognition Neural Network. 2022.** (Referência para modelos de alta precisão em laptops e dispositivos móveis).
- j. **WANG, J. et al. Video-based real-time monitoring of engagement in E-learning using MediaPipe through multi-feature analysis. 2025.** (Principal referência para a implementação via MediaPipe e fusão de características).